

Proiect la Probabilități și Statistică

Aplicații R, simulare și Shiny

Membri: Ciobotenco Vlad-Andrei, Fieraru Edward Alexandru, Licaret Matei

Mai 2026

Cuprins

1	Echipa și Rolurile Membrilor	3
2	Problema 1: Evenimente rare - detecție și simulare	3
2.1	Descrierea Problemei	3
2.2	Pachete Utilizate	3
2.3	Modelul Probabilistic Implementat	3
2.4	Strategii de Verificare	4
2.5	Definirea Indicatorului de Eficiență și a Funcției de Cost	5
2.6	Calculul Metricilor de Performanță	5
2.7	Grafice și Histograme	7
2.8	Evoluția probabilității de detecție în funcție de procentul de verificare . .	9
2.9	Simularea unui scenariu. Raportul mediei cu variabilitatea	10
2.10	Discuție: Probabilități Teoretice vs. Probabilități Empirice	11
2.11	Concluzie Finală	12
3	Problema 2: Aplicație Shiny pentru transformări de variabile aleatoare continue	13
3.1	Descrierea Problemei	13
3.2	Aspecte Teoretice Folosite	13
3.3	Pachetele R Utilizate	14
3.4	Structura Aplicației și Interfața	14
3.5	Modulul Unidimensional: $Y = g(X)$	15
3.6	Interpretarea Automată	15
3.7	Modulul Bidimensional: $Z = h(X, Y)$	16
3.8	Validarea Inputurilor	17
3.9	Capturi din Aplicație și Exemple Concrete	17
3.10	Comparația vizuală pentru diferite valori ale corelației	19
3.11	Concluzii	19

1 Echipa și Rolurile Membrilor

- **Ciobotenco Vlad-Andrei** – Problema 1, documentație
- **Fieraru Edward-Alexandru** – Problema 2, documentație
- **Licăreț Matei** – Problema 2, documentație

2 Problema 1: Evenimente rare - detecție și simulare

Această problemă explorează monitorizarea unui sistem informatic care procesează o medie de 5000 de cereri zilnic. Unele dintre aceste cereri sunt suspecte (evenimente rare), având probabilități mici de apariție ($p \in \{0.001, 0.005, 0.02\}$). Obiectivul este de a simula acest trafic pe parcursul unui an, de a aplica diverse strategii de detecție și de a minimiza riscul (nedetecția) raportat la costul operațional al verificărilor.

2.1 Descrierea Problemei

Pentru a evalua performanța detecției, am construit o aplicație R care simulează traficul zilnic și aplică metode probabilistice de extragere. Evaluăm 3 praguri de probabilitate pentru cererile suspecte și comparăm o abordare clasică (verificare a unui procent fix din trafic) cu una adaptivă (bazată pe încărcarea sistemului). De asemenea, vom aplica o strategie nouă, inspirată din viața reală. Finalitatea simulării este determinarea strategiei optime din punct de vedere al costului total (verificări + penalizări) sau al eficienței (un indicator definit de noi).

2.2 Pachete Utilizate

Pentru implementarea simulărilor și analiza datelor, proiectul folosește un set de pachete esențiale din ecosistemul R. Pachetul principal utilizat este **tidyverse**, un meta-pachet dedicat științei datelor. Acesta integrează biblioteci precum *dplyr* și *tidyr* pentru manipulare, filtrarea și pivotarea eficientă a datelor rezultate din simulări, *purrr* (prin funcția `map_dfr`) pentru iterarea fluidă a scenariilor și *ggplot2* pentru crearea vizualizărilor și graficelor avansate. În plus, a fost inclus pachetul **patchwork**, folosit pentru combinarea intuitivă a mai multor grafice individuale într-o singură planșă de prezentare.

2.3 Modelul Probabilistic Implementat

Pentru a modela cât mai fidel un mediu de producție real, am utilizat următoarele distribuții de probabilitate:

- **Traficul total zilnic:** S-a utilizat distribuția *Binomială Negativă* ($\mu = 5000$, parametrul de dispersie $size = 5$). În comparație cu distribuția Poisson (unde media și varianța sunt egale), distribuția Binomială Negativă permite modelarea datelor cu *supradispersie*. Aceasta simulează în mod realist zilele cu fluctuații extreme de trafic (zile cu spike-uri din punct de vedere al cererilor pe care le primesc).

```
total_cereri <- rnbinom(zile_an, size = dispersia_nb, mu = media_zilnica)
```

- **Cererile suspecte:** Au fost modelate folosind distribuția *Binomială* ($N = \text{total_cereri}$, $p = p_suspect$), deoarece presupunem că fiecare cerere generată are o probabilitate independentă de a fi un eveniment malițios.

```
cereri_suspecte <- rbinom(zile_an, size = total_cereri, prob = p_suspect)
```

- **Procesul de detecție:** Deoarece cererile verificate sunt extrase din ansamblul total și evaluate, acest proces reprezintă o extragere *fără revenire*. Din punct de vedere logic, un sistem de securitate analizează o cerere o singură dată într-o sesiune de verificare, nepunând-o înapoi în "urnă". Astfel, probabilitatea de a găsi un număr exact de cereri suspecte într-un număr limitat de extrageri urmează natural o distribuție *Hipergeometrică*.

```
# rhyper(nr_zile, m_suspecte, n_normale, k_extrageri)
detectate_A <- rhyper(zile_an, cereri_suspecte, cereri_normale, verificate_A)
```

2.4 Strategii de Verificare

Au fost implementate și evaluate trei strategii principale de alocare a efortului de verificare zilnică:

1. **Strategia A (Procent fix):** Verifică un procent fix din traficul fiecărei zile, stabilit la 10%.

```
pct_fix <- 0.10
verificate_A <- round(total_cereri * pct_fix)
```

2. **Strategia B (Adaptivă):** Ajustează procentul dinamic, luând în considerare stresul temporar asupra sistemului. Am definit un prag logic pe medie: în zilele cu activitate redusă sau normală (trafic $\leq$ media traficului) se verifică 5%, în timp ce în zilele cu vârfuri de trafic (potențiale aglomerări sau atacuri) se activează o verificare agresivă, alocând 20%. Eficiența acestei strategii depinde în mod principal de pragul ales.

```
pct_adaptiv <- ifelse(total_cereri > mean(total_cereri), 0.20, 0.05)
verificate_B <- round(total_cereri * pct_adaptiv)
```

3. **Strategia C (Număr fix):** Limitează efortul computațional zilnic la un număr maxim fix de cereri verificate (în cazul nostru, 1000 de cereri). Această abordare garantează că resursele alocate securității nu sunt suprasolicitate și nu blochează fluxul de producție în zilele cu atacuri DDoS (sau spike-uri extreme). Dezavantajul major este că, o dată atins plafonul, orice trafic excedentar rămâne neverificat.

```
nr_maxim_cereri <- 1000
verificate_C <- pmin(nr_maxim_cereri, total_cereri)
```

2.5 Definirea Indicatorului de Eficiență și a Funcției de Cost

Pentru o evaluare complexă, am creat două mijloace de analiză a eficienței și a costului. Scopul lor este de a ne ajuta să ne formăm o idee în legătură cu punctele forte și slabe ale fiecărei strategii.

- **Indicatorul de Eficiență (Randament):** A fost definit ca raportul dintre proporția medie a cererilor suspecte detectate zilnic și ponderea procentuală a traficului care a fost verificat.

$$\text{Eficiență} = \frac{\text{Proporție Medie Detectate}}{\text{Medie (Procent Trafic Verificat)}}$$

Acesta reprezintă o formă de Return-On-Investment: cu cât randamentul este mai mare, strategia detectează procentual mai mult în schimbul unui număr de verificări limitat.

```
Eficienta = Prop_Medie_Detectate / mean(Verificate / Total_Cereri)
```

- **Funcția de Cost Total:** Am definit formal riscul prin stabilirea unui cost per verificare de $c_1 = 2$ unități, respectiv o penalizare majoră per incident suspect ratat de $c_2 = 200$ unități. Astfel:

$$C = c_1 \cdot \text{număr_verificări} + c_2 \cdot \text{cereri_suspecte_nedetectate}$$

```
cost_verificare <- 2
cost_nedetected <- 200
```

```
Cost_Total = (sum(Verificate) * cost_verificare) +
              (sum(Nedetected) * cost_nedetected)
```

O astfel de asignare a costurilor favorizează verificarea unui număr mai mare de cereri, cu mențiunea că toate cererile nedetectate reprezintă un cost de 100 de ori mai mare.

2.6 Calculul Metricilor de Performanță

Pentru a evalua și compara în mod obiectiv strategiile de verificare propuse, am utilizat funcțiile de agregare din pachetul `dplyr` pentru a calcula un set de cinci metrici esențiale pentru fiecare scenariu simulat:

- **Probabilitatea empirică de a detecta cel puțin o cerere suspectă într-o zi:** A fost calculată ca media zilelor (din cele 365) în care numărul detecțiilor a fost strict mai mare decât zero. În R, expresia logică `Detectate > 0` este evaluată ca un vector de 0 (Fals) și 1 (Adevărat), iar media acestuia ne oferă direct probabilitatea empirică.

```
Prob_Detectie_1_Zi = mean(Detectate > 0)
```

- **Proporția medie de cereri suspecte detectate:** Această metrică măsoară procentul de amenințări prinse. Pentru a evita erorile de tip "împărțire la zero" (*NaN*) în zilele perfect curate (unde *Suspecte* = 0), am introdus o instrucțiune condițională care alocă valoarea 0 în astfel de situații.

```
Prop_Medie_Detectate = mean(ifelse(Suspecte == 0, 0, Detectate / Suspecte))
```

- **Proporția medie de cereri suspecte nedetectate:** Reprezintă complementul metricii anterioare și cuantifică procentul de "scăpări" ale sistemului de securitate. La fel ca mai sus, am tratat separat cazurile cu 0 suspecti.

```
Prop_Medie_Nedetectate = mean(ifelse(Suspecte == 0, 0, Nedetectate / Suspecte))
```

- **Numărul mediu de verificări efectuate zilnic:** Arată "efortul" brut depus de sistem. Am extras media simplă a coloanei corespunzătoare numărului de verificări efectuate de fiecare strategie.

```
Medie_Verificari = mean(Verificate)
```

- **Indicator de Eficiență (Randamentul Detecției):** Ca indicator propriu de evaluare, echipa a definit *Eficiența* drept raportul dintre proporția amenințărilor detectate și efortul procentual depus (cât la sută din trafic a fost evaluat). Un scor ridicat indică o strategie inteligentă, care maximizează rata de detecție cu un număr minim de verificări (un ROI decizional excelent).

```
Eficienta = Prop_Medie_Detectate / mean(Verificate / Total_Cereri)
```

	P_Scenariu	Strategie	Prob_Detectie_1_Zi	Prop_Medie_Detectate	Prop_Medie_Nedetectate	Medie_Verificari	Eficienta
	<fct>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	0.001	A	0.405	0.104	0.871	499.	1.04
2	0.001	B	0.370	0.106	0.869	716.	0.897
3	0.001	C	0.688	0.258	0.718	1000	1.06
4	0.005	A	0.868	0.0974	0.903	499.	0.974
5	0.005	B	0.764	0.118	0.882	716.	0.994
6	0.005	C	0.986	0.244	0.756	1000	1.00
7	0.02	A	0.997	0.0983	0.902	499.	0.983
8	0.02	B	0.978	0.117	0.883	716.	0.991
9	0.02	C	1	0.243	0.757	1000	0.997

Figura 1: Valorile metricilor

Ansamblul acestor calcule a fost sintetizat în cod cu ajutorul instrucțiunii `summarise()`, grupând automat rezultatele în funcție de strategia utilizată (A, B sau C) și de probabilitatea scenariului de risc (`p_suspect`).

Din câte se poate observa din Figura 1, strategia C are cele mai bune valori la toate metricile, indiferent de probabilitatea de generare a unei cereri suspecte. Această strategie își dovedește aplicabilitatea în viața reală, fiind inspirată din capacitățile limitate ale serverelor.

2.7 Grafice și Histograme

În această secțiune sunt centralizate vizualizările empirice fundamentale generate pentru scenariul mediu ($p = 0.005$). Structura modulară de mai jos permite urmărirea caracteristicilor inputului rețelei comparativ cu indicatorii de performanță ai strategiilor.




Figura 2: Raportul cererilor suspecte din volumul total zilnic.




Figura 3: Histograma frecvenței incidentelor detectate.

Prin intermediul figurii 2 putem observa care este frecvența numerelor de cereri suspecte pe parcursul unui an calendaristic. Se observă că în majoritatea zilelor numărul de cereri suspecte se învârtă în jurul valorii de 20.

În figura 3 se poate observa câte cereri suspecte a putut să detecteze fiecare strategie, raportat la un an calendaristic. Se pare că strategia C se detașează de strategiile A și B prin modul cum sunt dispuse valorile pe histogramă.




Figura 4: Randamentul detecției per unitate de efort depus.




Figura 5: Distribuția costului total agregat (A vs. B).

Figura 4 surprinde valorile indicatorului de eficiență în funcție de strategia aleasă. Practic, strategia C este cea mai bună când vine vorba de randament. În același timp, Figura 5 surprinde valorile costului total raportat la strategia utilizată. În acest caz, strategia A câștigă când vine vorba de o probabilitate mică și medie de apariție a unei cereri suspecte, având un cost total minim.




Figura 6: Evoluția zilnică a cererilor suspecte/detectate.

În figura 6 este prezentată o analiză de ansamblu a primelor 60 de zile (pentru lizibili-

tate) a rezultatelor fiecărei strategii utilizate. În condițiile în care strategiile A și B sunt flexibile (procent fix, procent adaptiv), strategia C rămâne constantă datorită plafonului absolut setat.

2.8 Evoluția probabilității de detecție în funcție de procentul de verificare

Pentru a înțelege pragul minim optim de de verificare a cererilor, graficul de mai jos evidențiază transformarea directă a probabilității de identificare a cererilor malițioase odată cu suplimentarea volumului de verificări zilnice de la 1% la 30%.




Figura 7: Curba sensibilității detecției raportată la creșterea efortului operațional (B).

	Procent_Verificare	Prob_Detecție_Min_1	Proportie_Medie_Detectata
1	1%	0.2082192	0.009278389
2	5%	0.6739726	0.048305948
3	10%	0.8767123	0.094825861
4	20%	0.9671233	0.191007086
5	30%	0.9972603	0.300770159

Figura 8: Analiza probabilitatii de detecție in functie de procentul de cereri verificate (B)

Metricile și graficul de mai sus prezintă proporția medie de cereri suspecte detectate și probabilitatea de detecție zilnică pentru mai multe procente de verificare a cererilor. Aceste procente se sunt aplicate în cadrul strategiei A. Se observa cum proporția de cereri suspecte prinse crește liniar, în timp ce probabilitatea de detecție zilnică are o creștere asimptotică.

Se efectuează același procedeu și pentru strategia B.




Figura 9: Curba sensibilității detecției raportată la creșterea efortului operațional (A).

	Scenariu_Verificare	Prob_Detecție_Min_1	Proportie_Medie_Detectata
1	Mic: 1% / Mare: 5%	0.4465753	0.02810755
2	Mic: 2% / Mare: 10%	0.5616438	0.05309764
3	Mic: 5% / Mare: 15%	0.8136986	0.09965904
4	Mic: 5% / Mare: 20%	0.7616438	0.11597930
5	Mic: 10% / Mare: 30%	0.8876712	0.19251219

Figura 10: Analiza probabilitatii de detectie in functie de procentul de cereri verificate (B)

Pentru strategia B se observă cum creșterea proporției de cereri suspecte detectate variază în funcție de raportul dintre procentul de verificare mic și cel mare. De asemenea, probabilitatea de detecție zilnică crește liniar, cu o mică excepție la cea de-a treia pereche de procente.

2.9 Simularea unui scenariu. Raportul mediei cu variabilitatea

Rularea de tip Monte Carlo ne permite să observăm stabilitatea tendințelor centrale (mediilor) în opoziție directă cu variabilitatea (deviația standard și fluctuațiile) la nivelul întregului an calendaristic.




Figura 11: Analiza dispersiei și consistența rezultatelor estimate prin modelare probabilistică.

	Strategie	Medie_Cost	Variabilitate_SD	Cost_Min	Cost_Max
	<chr>	<db 1>	<db 1>	<db 1>	<db 1>
1	Cost_A	2006372.	50122.	1870482	2177524
2	Cost_B	2083445.	51792.	1932178	2269636
3	Cost_C	2188676.	46508.	2058912	2352260

Figura 12: Rezultatele analizei mediei și a variabilității în raport cu strategia

Graficul de tip boxplot prezentat mai sus sugerează eficiența din punct de vedere al costului pe o perioadă de 1000 de ani. Se observă cum strategia de tip A are un cost total minim, rezultat ce poate fi corelat cu histograma costului total pe un an.

Punctele de tip outliers reprezintă anomalii sau zile în care detecția a fost inefficientă și au existat multe cereri suspicioase nedectate, fapt ce atrage un cost de penalizare ridicat.

2.10 Discuție: Probabilități Teoretice vs. Probabilități Empirice

În analiza performanței strategiilor de detecție a cererilor suspecte, s-a optat pentru o evaluare bazată pe simulări Monte Carlo ($N = 1000$ de iterații) în detrimentul unui calcul analitic pur. Această decizie subliniază diferențele fundamentale dintre probabilitățile teoretice și cele estimate empiric.

Probabilitățile teoretice reprezintă valoarea asimptotică exactă a unui eveniment și se obțin prin aplicarea directă a teoremelor matematice și a funcțiilor de masă specifice distribuțiilor (de exemplu, distribuția Binomială Negativă pentru volumul de trafic, Binomială pentru generarea suspectilor și Hipergeometrică pentru extragerile fără revenire).

Deși oferă o precizie matematică absolută, calculul lor analitic devine adesea impracticabil în scenarii dinamice. Un exemplu clar este *Strategia B (Adaptivă)*, unde volumul de extrageri este condiționat de media fluctuațiilor de trafic, transformând calculul teoretic într-o problemă cu variabile aleatoare compuse, extrem de greu de rezolvat manual.

Pe de altă parte, **probabilitățile practice (empirice)** sunt derivate din frecvența relativă a apariției evenimentelor în urma repetării experimentului de un număr mare de ori, folosind generatoare de numere pseudo-aleatoare. Conform *Legii Numerelor Mari*, aceste estimări converg către probabilitățile teoretice o dată cu creșterea numărului de simulări (în acest caz, 1000 de "ani" simulați).

Avantajul major al abordării empirice (Monte Carlo) este flexibilitatea sa absolută. Aceasta ne-a permis să integrăm fără efort matematic un model complex de costuri (costuri de verificare vs. penalizări pentru nedetectare). Mai mult, simularea practică ne oferă nu doar valoarea medie așteptată, ci ne permite să capturăm *variabilitatea* sistemului. Într-un context de securitate și business, înțelegerea riscului în scenariile cele mai pesimiste ("cozile" distribuției) este la fel de importantă ca și cunoașterea mediei teoretice.

2.11 Concluzie Finală

Alegerea strategiei optime trebuie să ia întotdeauna în considerare contextul și obiectivul principal de business. Dacă intenționăm să obținem cel mai bun ROI (*Return on Investment* / eficiență maximă raportată la efort), atunci cea de-a treia strategie (**Strategia C**) este cea mai bună. Pe de altă parte, dacă obiectivul este strict minimizarea costului total (costul verificărilor cumulat cu cel al penalizărilor), atunci prima strategie (**Strategia A**) reprezintă cea mai bună alegere.

3 Problema 2: Aplicație Shiny pentru transformări de variabile aleatoare continue

Această problemă constă în dezvoltarea unei aplicații interactive în *Shiny* care permite studiul vizual și numeric al transformărilor aplicate variabilelor aleatoare continue. Utilizatorul alege o repartiție pentru o variabilă aleatoare X , generează un eșantion, aplică o transformare $Y = g(X)$ și compară empiric distribuția lui X cu cea a variabilei transformate Y . Corectitudinea simulării este verificată suprapunând peste histograma empirică densitatea de probabilitate teoretică corespunzătoare repartiției alese. Aplicația tratează atât cazul unidimensional, cât și o componentă bidimensională, în care se construiește o nouă variabilă $Z = h(X, Y)$ din perechea generată.

3.1 Descrierea Problemei

Scopul aplicației este de a oferi o platformă didactică ce ilustrează cum modifică o funcție deterministă g forma, simetria și suportul unei distribuții de probabilitate. Aplicația este structurată în două tab-uri principale: un modul **unidimensional** ($Y = g(X)$) și un modul **bidimensional** ($Z = h(X, Y)$). Pentru fiecare modul, utilizatorul controlează interactiv repartiția de bază, parametrii acesteia, dimensiunea eșantionului și transformarea aplicată, iar aplicația răspunde cu reprezentări grafice și indicatori statistici recalculați. Întreaga simulare este declanșată explicit printr-un buton *Simulează*, pentru a evita re-actualizarea haotică a graficelor la fiecare modificare minoră de parametru.

3.2 Aspecte Teoretice Folosite

Fundamentul matematic al aplicației este **metoda transformării variabilelor aleatoare**. Dacă X este o variabilă aleatoare continuă cu densitatea f_X , iar g este o funcție aplicată acesteia, atunci $Y = g(X)$ este la rândul ei o variabilă aleatoare, a cărei distribuție depinde atât de f_X , cât și de natura lui g (monotonie, injectivitate, domeniu de definiție).

- **Repartiții continue utilizate:** Aplicația permite generarea din patru repartiții continue clasice: Normală $N(\mu, \sigma^2)$, Exponențială $Exp(\lambda)$, Uniformă $Unif(a, b)$ și Gamma $\Gamma(\alpha, \theta)$. Acestea acoperă atât cazuri simetrice (Normală), cât și asimetrice și mărginite inferior (Exponențială, Gamma).
- **Transformări relevante:** Cazurile $Y = X^2$ și $Y = |X|$ ilustrează pierderea bijectivității și apariția suportului strict pozitiv. Un rezultat teoretic important este că pentru $X \sim N(0, 1)$, variabila $Y = X^2$ urmează o repartiție χ^2 cu un grad de libertate, lucru observabil direct în histograma generată. Transformările $\log(x)$ și e^x ilustrează compresia, respectiv dilatarea cozilor distribuției, iar funcția sigmoidă $g(x) = \frac{1}{1+e^{-x}}$ comprimă întregul suport real în intervalul $(0, 1)$.
- **Repartiția normală bidimensională:** Pentru componenta 2D, perechea (X, Y) poate fi generată dintr-o distribuție normală bivariată parametrizată prin vectorul mediilor și matricea de covarianță. Covarianța se calculează ca $Cov(X, Y) = \rho \cdot \sigma_X \cdot \sigma_Y$, iar coeficientul de corelație ρ controlează gradul de dependență liniară între cele două variabile.

- **Verificarea empirică:** Conform Legii Numerelor Mari, pentru un eșantion suficient de mare, histograma de frecvențe relative (densitate empirică) converge către densitatea teoretică. Suprapunerea curbei teoretice peste histograma empirică validează vizual corectitudinea generatorului de numere aleatoare.

3.3 Pachetele R Utilizate

Aplicația a fost construită folosind următoarele pachete:

- **shiny** – nucleul aplicației interactive (interfața reactivă și serverul de calcul);
- **bslib** – organizarea modernă a interfeței (layout de tip *navbar*, *card*-uri și temă vizuală personalizată cu fonturi Google);
- **ggplot2** – generarea histogramelor, a curbelor de densitate și a scatterplot-ului;
- **dplyr** – prelucrarea și manipularea datelor generate;
- **MASS** – funcția `mvrnorm()` pentru generarea eșantioanelor din repartiția normală bidimensională.

3.4 Structura Aplicației și Interfața

Interfața este organizată cu `page_navbar` în două tab-uri principale, fiecare conținând un card de configurare în partea superioară și zonele de rezultate dedesubt:

1. **Tab-ul 1D (Unidimensional):** Permite selectarea repartiției lui X , ajustarea parametrilor (afișați dinamic prin `conditionalPanel` în funcție de repartiția aleasă), alegerea dimensiunii eșantionului și a transformării $g(x)$. Rezultatele includ histogramele pentru X și Y afișate alăturat, tabelele cu indicatori statistici și un mesaj de interpretare automată.
2. **Tab-ul 2D (Bidimensional):** Permite alegerea modului de generare a perechii (variabile independente sau normală bidimensională), configurarea parametrilor și selectarea transformării $h(X, Y)$. Rezultatele includ un scatterplot al perechilor (X_i, Y_i) , o matrice de analiză a dispersiei și histogramele separate pentru X , Y și Z .

În figura de mai jos este prezentat panoul de configurare al modului bidimensional, în modul *Normală 2D*. Utilizatorul poate seta mediile μ_X, μ_Y , deviațiile standard σ_X, σ_Y , coeficientul de corelație ρ (prin slider), dimensiunea eșantionului și transformarea $h(X, Y)$, simularea fiind declanșată de butonul *Simulează*.

Configurare Simulare 2D

Tip generare:

☐ Independente

☒ Normală 2D

μ_X :

σ_X :

μ_Y :

σ_Y :

ρ :

Eșantion (n):

Funcția $h(X,Y)$:

☐ $X + Y$

☐ $X - Y$

☒ $\sqrt{X^2 + Y^2}$

☐ $X * Y$

Simulează

Figura 13: Panoul de configurare al modului bidimensional (modul Normală 2D).

3.5 Modulul Unidimensional: $Y = g(X)$

Generarea datelor este încapsulată într-un bloc `eventReactive` legat de butonul *Simulează*, astfel încât eșantionul este recalculat doar la cerere explicită. După generarea lui X din repartiția aleasă, se aplică una dintre cele cinci transformări obligatorii:

$$g(x) = x^2, \quad g(x) = |x|, \quad g(x) = \log(x), \quad g(x) = e^x, \quad g(x) = \frac{1}{1 + e^{-x}}.$$

Pentru fiecare transformare, aplicația afișează histograma valorilor generate suprapusă cu estimarea densității empirice (`geom_density`), precum și un set complet de indicatori numerici: media empirică, dispersia empirică, deviația standard, minimul, maximul, mediana și cele trei cuartile.

Tratarea cazurilor speciale. Transformarea $\log(x)$ nu este definită pentru valori negative sau nule. Aplicația identifică valorile invalide ($x \leq 0$) printr-o mască logică, le exclude din calcul și informează utilizatorul prin mesaj câte valori au fost eliminate:

```
# Exemplu de tratare a valorilor excluse și aplicarea măștii de validare
if(input$trans_g == "log") {
  valid_mask <- x > 0
  y[valid_mask] <- log(x[valid_mask])

  if(sum(!valid_mask) > 0) {
    msg <- paste("Atenție: s-au exclus", sum(!valid_mask),
                "valori <= 0 pentru care log(X) nu este definit.")
  } else {
    msg <- "Transformarea a comprimat valorile mari și
          a creat cozi lungi pentru valorile subunitare."
  }
}
```

În mod similar, transformarea e^x poate produce valori care depășesc limita de reprezentare numerică a programului; aceste valori infinite sunt filtrate (`is.finite`) înainte de reprezentarea grafică, iar utilizatorul este avertizat asupra numărului de observații excluse.

3.6 Interpretarea Automată

Aplicația include o secțiune de interpretare automată care afișează mesaje contextuale despre efectul transformării. Fiecare transformare generează un mesaj descriptiv specific (de exemplu, ridicarea la pătrat produce valori strict pozitive, logaritmul comprimă valorile mari, sigmoida mărginește valorile în $(0, 1)$). Suplimentar, aplicația calculează **coeficientul de asimetrie (skewness)** empiric atât pentru X , cât și pentru Y :

$$\text{Skewness} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\hat{\sigma}^3},$$

și, comparând cele două valori, generează automat un mesaj despre modificarea simetriei distribuției (de exemplu, dacă o distribuție inițial simetrică devine asimetrică în urma transformării).

Acest procedeu logic a fost implementat astfel în aplicație:

```
# Calculul empiric pentru asimetrie (skewness)
sk_x <- (sum((res$og_x - mean(res$og_x))^3) / length(res$og_x)) / (sd(res$og_x)^3)
sk_y <- (sum((res$y - mean(res$y))^3) / length(res$y)) / (sd(res$y)^3)

# Evaluarea pragurilor de simetrie și generarea mesajului
if(!is.na(sk_x) && !is.na(sk_y)) {
  if(abs(sk_x) < 0.3 && abs(sk_y) > 0.5)
    sym_msg <- "Transformarea a modificat simetria distribuției (a devenit asimetrică)
  if(abs(sk_x) > 0.5 && abs(sk_y) < 0.3)
    sym_msg <- "Transformarea a modificat simetria distribuției (a devenit mai simetr
  }
}
```

3.7 Modulul Bidimensional: $Z = h(X, Y)$

Componenta bidimensională permite generarea perechii (X, Y) în două moduri distincte:

1. **Variabile independente:** X și Y sunt generate separat, fiecare din câte o repartiție aleasă independent de utilizator (Normală, Exponențială, Uniformă sau Gamma), cu parametrii proprii.
2. **Normală bidimensională:** Perechea (X, Y) este generată simultan din distribuția normală bivariată folosind `mvrnorm()`, pe baza vectorului mediilor (μ_X, μ_Y) și a matricei de covarianță construite din σ_X , σ_Y și coeficientul de corelație ρ ales prin slider.

Implementarea matricei de covarianță în Shiny arată astfel:

```
# Construirea matricei de covarianță și generarea eșantionului bivariat
mu <- c(input$biv_mu_x, input$biv_mu_y)
cov_xy <- input$biv_rho * input$biv_sd_x * input$biv_sd_y
sigma <- matrix(c(input$biv_sd_x^2, cov_xy,
                  cov_xy, input$biv_sd_y^2), 2, 2)

biv_data <- mvrnorm(n, mu, sigma)
x <- biv_data[, 1]
y <- biv_data[, 2]
```

Asupra perechii generate se aplică una dintre cele patru transformări bidimensionale obligatorii prin intermediul unui bloc condițional compact (`switch`):

```
# Aplicarea transformărilor 2D alese de utilizator pentru variabila Z
z <- switch(input$trans_h,
  "add" = x + y,
  "sub" = x - y,
  "dist" = sqrt(x^2 + y^2),
  "mul" = x * y)
```

Pentru fiecare simulare se calculează și se afișează într-o matrice de analiză: media empirică a lui X , Y și Z , dispersia empirică a celor trei variabile, covarianța empirică dintre X și Y și coeficientul de corelație empiric dintre X și Y . Vizual, modulul afișează un scatterplot al perechilor (X_i, Y_i) și histogramele individuale pentru X , Y și Z .

3.8 Validarea Inputurilor

Toate inputurile sunt validate prin funcția `validate(need(...))` înainte de generarea datelor, oferind mesaje de eroare clare în locul unor erori interne. Principalele verificări implementate sunt:

- deviațiile standard (σ) trebuie să fie strict pozitive, atât în cazul 1D, cât și în cel 2D;
- rata λ a repartiției exponențiale trebuie să fie strict pozitivă;
- parametrii repartiției Gamma (forma și scala) trebuie să fie strict pozitivi;
- pentru repartiția Uniformă se impune ca minimumul să fie strict mai mic decât maximumul;
- coeficientul de corelație ρ este restrâns prin construcție în intervalul $(-1, 1)$ prin folosirea unui `sliderInput` limitat la $[-0.99, 0.99]$;
- pentru $\log(X)$ se tratează explicit valorile pentru care transformarea nu este definită.

3.9 Capturi din Aplicație și Exemple Concrete

Exemplul 1 ($Y = X^2$ pentru $X \sim N(0, 1)$). Selectând repartiția Normală cu $\mu = 0$, $\sigma = 1$ și transformarea $g(x) = x^2$, se observă cum o distribuție simetrică în jurul originii devine strict pozitivă și puternic asimetrică la dreapta, ilustrând legătura cu repartiția χ^2 cu un grad de libertate.




Figura 14: Histograma lui $X \sim N(0, 1)$ cu densitatea teoretică suprapusă.




Figura 15: Histograma lui $Y = X^2$ (formă specifică χ_1^2).

Exemplul 2 (transformarea $\log(X)$). Pentru o repartiție care produce și valori subunitare, transformarea logaritmică comprimă valorile mari și extinde coada pentru valorile mici, modificând complet forma distribuției. Aplicația semnalează cazurile în care apar valori ≤ 0 ce nu pot fi transformate.

Interpretare Automată: Atenție: s-au exclus 495 valori ≤ 0 pentru care $\log(X)$ nu este definit. Transformarea a modificat simetria distribuției (a devenit asimetrică).




Figura 16: Efectul transformării $g(x) = \log(x)$ asupra distribuției și mesajul de interpretare automată.

Exemplul 3 (componenta bidimensională). Pentru o pereche (X, Y) generată din distribuția normală bidimensională (cu $\mu_X = 15$, $\mu_Y = 65$, $\sigma_X = 40$, $\sigma_Y = 69$) și transformarea $Z = \sqrt{X^2 + Y^2}$, aplicația afișează histogrammele celor trei variabile alături de estimarea densității empirice. Se observă că distribuțiile marginale ale lui X și Y rămân aproximativ normale, în timp ce variabila transformată Z devine strict pozitivă și asimetrică la dreapta, deoarece norma euclidiană nu poate lua valori negative.




Figura 17: Histogrammele marginale ale lui X , Y și ale variabilei transformate $Z = \sqrt{X^2 + Y^2}$.

3.10 Comparația vizuală pentru diferite valori ale corelației

Pentru cazul normal bidimensional, am comparat comportamentul scatterplot-ului la trei valori ale coeficientului de corelație: $\rho = -0.5$, $\rho = 0$ și $\rho = 0.5$, păstrând ceilalți parametri constanți. Această comparație evidențiază modul în care dependența liniară dintre X și Y influențează forma norului de puncte. Pentru $\rho = -0.5$ norul este o elipsă orientată descrescător (corelație negativă, valoare empirică ≈ -0.48), pentru $\rho = 0$ punctele formează un nor aproximativ circular fără tendință liniară (corelație empirică ≈ 0.01), iar pentru $\rho = 0.5$ elipsa este orientată crescător (corelație pozitivă, valoare empirică ≈ 0.46). Se confirmă astfel că valorile empirice estimate prin simulare sunt apropiate de valorile teoretice ale lui ρ .




Figura 18: Compararea scatterplot-urilor (X, Y) pentru $\rho = -0.5$, $\rho = 0$ și $\rho = 0.5$.

3.11 Concluzii

Aplicația Shiny dezvoltată oferă un instrument interactiv complet pentru studiul transformărilor de variabile aleatoare continue, atât în cazul unidimensional, cât și în cel bidimensional. Suprapunerea densităților teoretice peste histogramele empirice confirmă corectitudinea generatorului și ilustrează practic Legea Numerelor Mari. Modulul de interpretare automată și sistemul robust de validare a inputurilor fac aplicația accesibilă și unui utilizator care nu cunoaște codul sursă, în timp ce tratarea explicită a cazurilor speciale (valori în afara domeniului de definiție, valori care depășesc limita de calcul) asigură rularea fără erori în toate scenariile testate.